

서울대학교에도 스타벅스가?

Clustering, Classification model을 통한 스타벅스 입점 예측

EDA

DATA INTEGRITY

FEATURE ENG.

CLUSTERING

목차

1. 프로젝트 주제 및 분석 파이프라인
2. 초기 Feature 설계
3. 데이터 정합성 검토: 이상치 및 결측치 처리
4. 다변량 분석과 Feature Engineering
5. 클러스터링 결과: 스타벅스 입지 유형화
6. 향후 계획

프로젝트 주제 및 분석 파이프라인

Why Starbucks? Why SNU?

스타벅스 입지 패턴과의 유사도 예측 문제 정의

서울대학교에는 정말 스타벅스가 들어올 수 있을까?

직관적 통설을 데이터 마이닝으로 검증한다.

MYTH

"스타벅스는 오직 돈 되는 자리에만 간다"

시장에 널리 퍼진 직관적 통설.
감각과 자본력에 의존한다는 오해.

직관·감성

REALITY · ATLAS

'아틀라스(Atlas)' 자체 상권 분석 시스템

철저한 직영점 체제 아래, 기존 매장과 거리·인구 통계·
트래픽 패턴 등 방대한 데이터를 분석해 최적 입지를 도출.

데이터·알고리즘

PROJECT GOAL

서울 681개의 스타벅스 매장 입지 패턴을 유형화하고, 서울 전체 카페 데이터를 바탕으로
스타벅스형 입지 적합도를 예측한다.

→ 서울대 관악캠퍼스 후보지의 '스타벅스형 입지 적합도'를 정량 평가하는 것이 최종 목표.

분석 파이프라인 — Data Mining Term Project

데이터 수집 및 분석 -> Feature Engineering -> Clustering -> Classification -> 결론 도출

01

데이터 수집 및 분석

18개 초기 입지 지표 도출

- 스타벅스 API
- 소상공인 상가정보
- 서울시 공공데이터

02

Feature Engineering

이상치, 결측치 탐지 및 보완
EDA, 시각화
변수 보완 및 확정

03

Clustering

스타벅스 매장 유형 분류

04

Classification

스타벅스 입점 확률 모델링

05

결론 도출

캠퍼스 좌표 입력 및 결론 도출

CURRENT PROGRESS — 중간 발표 시점

STEP 1-3 완료: Clustering을 바탕으로 인사이트 도출

681

서울 스타벅스 매장
(분석 대상)

16

최종 확정 피쳐
(18 → 16)

5

K-means 군집
(입지 페르소나)

초기 feature 설계

Data Acquisition · Feature Architecture · Radius Selection

카페 하나의 좌표를 교통, 인구, 상권, 경제 정보를 담은 입지 벡터로 변환한다.

데이터 출처와 분석 단위

Seoul_cafe_model_feature_v1.csv

스타벅스 매장

Starbucks Korea API

매장명
위도
경도
주소

서울 카페 전체

소상공인 상가정보

카페 위도, 경도
브랜드
업종

교통 데이터

서울시 공공데이터

지하철역 위치
지하철역별 승하차량
버스정류장 위치

상권 데이터

소상공인 상권정보

음식점, 소매업, 편의점
카페 정보

인구, 경제 데이터

서울시/공공 통계

소득
직장인구, 생활인구
공시지가



Positive Label 대상, Clustering 대상



Classification 시 Negative Sample



접근성, 유동성 측정



주변 상권 밀도 측정



구매력, 입지 가치 결정

RADIUS PRINCIPLE

분석 단위는 행정동이 아니라 '개별 카페 좌표'이다

모든 변수는 최종적으로 매장 1개 행에 결합된다.

초기 18개 입지 지표 설계 (Feature Architecture)

Seoul_cafe_model_feature_v1.csv

PILLAR 1 교통 접근성

4

- 지하철 거리
- 지하철역 수 (500m)
- 근접역 일일 승하차량
- 버스정류장 수 (300m)

PILLAR 2 교통 유동인구

3

- 아침 피크 (500m)
- 점심 피크 (500m)
- 저녁 피크 (500m)

PILLAR 3 상권 밀도

6

- 음식점 수 (500m)
- 소매업 수 (500m)
- 편의점 수 (500m)
- 독립카페 (500m)
- 저가카페 (500m)
- 기타프랜카페 (500m)

PILLAR 4 지역 경제 및 집적 효과

5

- 평균 소득
- 직장인구
- 생활인구
- 공시지가
- 인근 스타벅스 거리

RADIUS PRINCIPLE

초기 18개 변수는 접근성-유동성-상권성-경제성/집적성 4축으로 설계

이후 EDA와 상관분석을 통해 16개 최종 feature로 정제

반경 기반 변수 생성 원리

반경 기반 변수는 임의로 선정하지 않고, 변수의 의미에 따라 다른 공간 단위를 사용하였다.

Nearest Distance


Dist_nearest_subway
Dist_nearest_starbucks



입지의 즉각적인 접근성 측정을 위함.
가장 가까운 핵심 시설까지 얼마나 가까운가?

300m

Num_bus_stop_300m



매장에 실제로 접근할 수 있는 도보 접근권
300m는 일반인이 도보로 무리 없이 접근할 수
있는 거리 -> 매장 도달 가능성과도 연관

500m

num_subway_500m
subway_morning_peak_500m
subway_lunch_peak_500m
subway_evening_peak_500m
num_restaurants_500m
num_retail_500m
num_convenience_500m
independent_cafe_count_500m
low_price_cafe_count_500m
other_franchise_cafe_count_500m

인접 상권이 한 단위로 묶이는 범위
-> 매장이 위치한 상권 자체의 활성화 측정

반경은 임의로 고정하지 않고, 변수의 의미에 따라 선택한 공간 단위이다.

데이터 정합성 검토: 결측치, 이상치 처리

Data Integrity

결측치는 원인을 추적해 보정하고, 이상치는 제거하지 않고 해석한다.

데이터 정합성 검토: 결측치 처리

지리·행정 특성을 반영한 원인 기반 보정으로 공간 데이터의 왜곡을 방지

결측치 처리

ISSUE

지하철 승하차량 누락

(서울역 및 신분당선 4곳 데이터 누락)



ACTION

신분당선 외부 데이터 별도 확보 및
수동 매핑

RESOLVED

ISSUE

행정동의 개편(분동)

(신설동 분동)



ACTION

이전 행정동 데이터를 기준으로 보정

RESOLVED

ISSUE

행정동 자료의 부재

(row data 자체의 결측)





ACTION

인접 동의 평균값으로 대체

RESOLVED

결측치 처리 결과: Missing value: 0



데이터 정합성 검토: 이상치 해석



이상치 보존을 최우선 원칙, 클러스터링의 필요성 확인

이상치 해석

"이상치는 에러가 아닌 입지 페르소나다"

IQR 기준을 초과하지만,
제거 시 핵심 상권 정보가 소실된다.

- 01 **목적지형 매장**
더북한산·망원한강공원·서울타워
- 02 **차량 접근 (DT)**
신월IC·DT·화곡DT
- 03 **특수 시설 입점**
이케아 강동·양재하나로마트



제거하면 모델이 일반 역세권 스타벅스만 학습하게 된다. 보존하여야 다양한 입지 전략 Clustering에서 포착 가능.


다변량 분석과 Feature Engineering

Redundancy - Skewness - Interpretability

18개의 초기 feature를 클러스터링 가능한 16개 입지 feature로 정제

상관 구조에서 드러난 변수 중복과 입지 패턴

$|r| \geq 0.5$ 를 강한 상관으로 정의하고, 18개 변수 $\times$ 18개 변수 상관행렬에서 45개의 강한 연결을 진단하였다.



패턴 A

$$r \geq 0.92$$

지하철 승하차인원의 완전한 중복

아침·점심·저녁 승하차인원의 평균 상관 $r=0.955$.
세 변수는 사실상 하나의 잠재 차원 $\rightarrow$ peak avg로 통합 처리.

패턴 B

$$r \geq 0.82$$

상권 밀도 축

음식점 — 편의점 — 독립카페의 $r \geq 0.82$ 삼각 구조.
셋은 '상권이 얼마나 발달했는가'를 묻는 지표들 → Clustering 해석 시 상권 밀도 축으로 해석.

패턴 C

$$r = 0.760$$

경제·인구의 동조화

직장인구 ↔ 생활인구 $r=0.760$.
 업무지구가 곧 생활 밀집지구인 서울의 도시 구조 반영.

핵심 Insight: The Agglomeration Effect

데이터상 스타벅스는 경쟁 카페와 다른 스타벅스가 이미 밀집한 상권에 함께 분포하는 경향을 보인다.

KEY CORRELATION

$$r = -0.51$$

상권 발달도 ↔ 인근 스타벅스 거리


음식점이 많을수록($r=-0.516$), 독립카페가 많을수록($r=-0.513$) 가장 가까운 다른 스타벅스와의 거리는 더 짧아진다.

통설

"카페가 많은 곳은
경쟁이 치열해 피해야 한다"

데이터적 진실

상권이 발달할수록
다른 스타벅스가 더 가까이 있다



MODELING IMPLICATION

스타벅스는 거대 상권의 파이를 나누며 '집적 효과(Agglomeration)'를 극대화하는 군집(Clustering) 패턴을 보인다.

→ 모델은 '경쟁 회피'가 아니라 '검증된 상권 집중'을 학습해야 한다.

Feature Engineering:18개 → 16개 피처 확정

중복된 변수는 줄이고, 왜도 큰 변수는 변환하고, 해석 가능한 입지 신호는 보존하였다.

1. 피크 3변수 평균 통합

아침 / 점심 / 저녁 피크 → **peak_avg**
평균 통합으로 다중공선성 제거 + 수학적 비례 유지

2. 이산형 변수 3범주화

지하철역 수 (500m) → **subway_count_cat (0 / 1 / 2+)**
IQR=0인 이산형 데이터의 연속형 취급 오류 보정

3. 왜도 변환

변수명	변환 전 왜도 (Skewness)	변환 후 왜도	변환 근거
지하철역 거리	3.29	~0.8	거리 감쇠 특성 반영
소매업 수 (500m)	2.71	~0.6	상권 변수 중 왜곡 가장 심함
스타벅스 거리	2.46	~0.7	인근 매장 집적 효과 반영

FINAL FEATURE SET

정제된 16개의 feature를 스타벅스 입지 유형을 구분하기 위한 clustering input으로 사용한다.

Clustering 결과: 스타벅스 입지 유형화

From Individual Stores to location personas

서울 스타벅스 681개 매장을 군집화한다.

Clustering 실험 설계

입점 여부 예측이 아니라, 기존 스타벅스 매장의 입지 유형을 찾는 비지도학습 설계

실험 개요	
분석 대상	서울 스타벅스 681개 매장
입력 데이터	Starbucks_features_final.csv
입력 Feature	16개 입지 변수
전처리	StandardScaler 표준화
시각화	PCA 2차 축소(설명분산 A=56.9%, B=51.8%)
비교 조건	A: 위경도 제외 / B: 위경도 포함

알고리즘 및 Feature Set 비교

세 가지 Clustering 알고리즘과 두 가지 Feature Set을 비교하였다.

알고리즘 비교

ALGORITHM COMPARISON		
Algorithm	사용 이유	한계
K-means	중심값 기반이라 cluster profile 해석이 쉬움	구형 클러스터 가정, 이상치에 민감
DBSCAN	노이즈, 특수 입지 탐지 가능	고차원 데이터에서 eps 설정에 민감
Hierarchical	덴드로그램으로 계층 구조 확인 가능	클러스터 크기 불균형 가능

Feature Set 비교

FEATURE SET COMPARISON		
Feature Set	구성	목적
A: 위경도 제외	16개 Feature	상권, 교통, 인구 특성만으로 유형화
B: 위경도 포함	16개 Feature + 위도, 경도	물리적 위치까지 비교하였을 때 비교

최적 k 결정과 최종 모델 결정

6개의 조건 중 가장 최적의 k값과 모델을 결정하였습니다.

1. 알고리즘별 최적의 k 값 선정 및 결과 비교

수학적 최적값

Silhouette score는 많은 경우 k=2를 최적으로 지시.
→ 단순 '강남 vs 비강남' 이분법이 됨.

비즈니스 해석

우리 목적은 단순 분류가 아니라, 스타벅스의 다양한 입점 전략(페르소나)을 이해하는 것.

최종 결론

목적지형·차량형·주거형 등 다양한 상권을
대변할 수 있도록 $k \geq 3$ 중에서 최고의 Silhouette score 가진 클러스터 수 각각 채택.

피처셋	알고리즘	클러스터수	노이즈	Silhouette	DB Index
[A] 위경도X	K-means	5	0	0.172	1.630
[A] 위경도X	DBSCAN	4	14	0.212	-
[A] 위경도X	Hierarchical	5	0	0.173	1.619
[B] 위경도O	K-means	4	0	0.145	1.849
[B] 위경도O	DBSCAN	5	41	0.148	-
[B] 위경도O	Hierarchical	4	0	0.160	1.681

2. 최종 모델 선정

Feature Set A와 B 비교

[A]가 [B]보다 일관되게 Silhouette score 높음
→ 위경도가 상권 특성 기반 클러스터링에 노이즈로 작용

[A] DBSCAN을 채택하지 않은 이유

Silhouette Score가 가장 높지만 인사이트를 뽑을 수 없음
1개의 거대 클러스터 + 소수의 작은 클러스터 패턴
615/41/7/7/noise
→ DBSCAN 알고리즘을 제외

[A] K-means VS [A] Hierarchical

Silhouette Score가 거의 동일함
0.172 VS 0.173

최종 결론

클러스터 크기 균형이 더 좋은 K-means 알고리즘 선택


[A] K-means k=5 클러스터 분포: 47 / 227 / 235 / 73 / 99

[A] Hierarchical k=5 클러스터 분포: 340 / 151 / 103 / 29 / 58

최종 결과: 5개 스타벅스 입지 페르소나

위경도를 제외한 16개 입지 feature 기반 K-means k=5 결과

C0 47 고소득오피스 복합형 평균소득·공시지가 高, 직장인구 多	C1 227 상업 활성화형 강남·홍대·신촌 등 핵심 상권	C2 235 주거 생활형 분포된 평범한 도시 입지
C3 73 도심 초밀집형 공시지가 매우 高, 명동 일대	C4 99 비역세권 / 외곽형 지하철 부재, 차량·목적지형	



서울 지도에 Cluster별 스타벅스 매장을 표시한 Figure

개선 방향 제안 및 향후 계획

From clustering Insight to SNU location simulation

입지 유형화를 바탕으로 서울대 후보지의 스타벅스형 입지 적합도를 측정한다.

Clustering 결과 심층 분석 방향 제안

Clustering 결과를 다각도로 분석하고, Classification을 위한 insight를 도출한다.

Silhouette score 0.172

고차원, 실측 데이터라는 점을 고려하여 유의미한 클러스터링이 이루어졌음을 확인.
실제 부동산 입지 분석 등 선행연구에서의 Silhouette score 역시 0.15 - 0.25 수준.

심층 분석

01

Clustering 간 경계 분석

- 고소득 오피스(C0)과 초번화가(C3) 클러스터는 둘 다 land_price가 높음. 일부 매장이 양쪽 경계에 위치할 가능성.
- 일반 상권(C2)과 비역세권(C4) 역시 경계가 흐릿할 가능성.
- Peak_avg가 높은 번화가(C1) 클러스터는 독립적일 것.

02

Feature별 클러스터 구분력 진단

- 각 변수가 클러스터를 얼마나 잘 구분하는지 진단
- 구분력 상위 변수와 하위 변수 판별
- 구분력 하위 변수를 심층 분석하여 Classification 단계에서 제거할 후보로 둬.

03

클러스터 안전성 분석

- K=5 결과가 과적합되었을 가능성
- 전체 681개 매장에서 80%를 무작위 샘플링하여 클러스터링을 여러 번 반복하고, 각 매장이 같은 클러스터에 배정될 확률을 측정하여 판단.

향후 계획

서울 전체 카페 데이터를 바탕으로 스타벅스형 입지 모델을 학습하고, 서울대 후보지를 동일한 feature 공간에 투영한다

01

Clustering 심층 분석 및 검증

- Hierarchical 결과(C0~C4)와 적합성 비교
- DBSCAN 노이즈 14개 매장의 페르소나 재해석
- 위경도 포함 vs 제외 피쳐셋 추가 검증

02

Classification 학습

- 비스타벅스 카페 21,624개 데이터 정합화 → $y=0$ 결정
- Logistic / Decision Tree / Random Forest 3종 비교
- VIF-SHAP 등 변수 중요도 정량화

03

서울대 후보지 시뮬레이션

- 학생회관·39동·정문 등 다양한 후보지 선정 및 좌표 매핑
- 동일 반경(300m·500m) 기준 16개 피쳐 산출
- 적합도 점수와 부족 요인 데이터 기반 설명

REMAINING TIMELINE

5/12 - 5/19

Classification 1차 구현
3종 모델 기본 학습

5/20 - 5/26

모델 고도화·튜닝
하이퍼파라미터 / 평가 비교

5/27 - 6/3

서울대 시뮬레이션
캠퍼스 좌표 입력 → 점수 산출

6월 2주

최종 발표
보고서 + 발표자료

Thank You

Q & A · 감사합니다

권오철 · 김강현 · 김예원 · 현승민